

1. Contextualização do TCC

1.1 O que é o projeto?

Este projeto foi desenvolvido como parte de um desafio proposto pela **Escola da Nuvem**, com o objetivo de reforçar, na prática, os conhecimentos adquiridos sobre computação em nuvem e, principalmente, sobre como os serviços da AWS podem ser utilizados para resolver problemas reais de negócio.

O desafio representa uma oportunidade de sair de uma abordagem puramente conceitual e aplicar os conhecimentos estudados durante nossa preparação para a certificação **AWS Certified Cloud Practitioner** na análise e construção de uma solução arquitetural.

Mais do que simplesmente selecionar serviços da AWS, o objetivo do projeto é compreender o problema apresentado, identificar suas necessidades e restrições e, a partir disso, avaliar como diferentes recursos da nuvem podem agregar valor ao negócio.

Essa abordagem também nos levou a perceber que o projeto envolve muito mais do que armazenamento de arquivos. Os documentos possuem um ciclo de vida, diferentes níveis de utilização ao longo do tempo, requisitos de segurança e um valor estratégico para o negócio. Dessa forma, decisões relacionadas à organização, acesso, retenção e custo dos dados passam a fazer parte da própria arquitetura da solução.

1.2 Por que acreditamos que seja um tema relevante?

O tema se torna especialmente relevante quando consideramos o crescimento da utilização de Inteligência Artificial e a importância dos dados que alimentam essas soluções. No cenário proposto, os documentos enviados pelos clientes representam a base histórica utilizada para a evolução futura dos modelos de IA da empresa. Assim, garantir que esses dados estejam organizados, protegidos, disponíveis quando necessários e economicamente sustentáveis ao longo do tempo é parte fundamental da estratégia do negócio.

Além disso, o cenário proposto está inserido em um contexto de crescimento significativo do mercado de Inteligência Artificial, suportado por dados expressivos do setor:

US\$ 2,59 T

INVESTIMENTO GLOBAL
EM IA EM 2026 (+47%)

US\$ 2,4 B

MERCADO DE IA NO
BRASIL (+30%)

95.2%

EMPRESAS COM IA
COMO PRIORIDADE EM
2026

45%

INVESTIMENTO FOCADO
EM INFRAESTRUTURA

- **Crescimento Global:** Segundo projeção da consultoria Gartner, o investimento global em inteligência artificial deve alcançar US\$ 2,59 trilhões em 2026, alta de 47% em relação ao ano anterior, com expectativa de chegar a quase US\$ 3,5 trilhões em 2027.
- **Cenário Nacional:** No Brasil, um estudo da IBM mostrou que 78% das empresas nacionais planejam ampliar seus investimentos em IA, e os gastos com IA no país devem ultrapassar US\$ 2,4 bilhões, crescimento de 30% em relação a 2024.

- **Adoção Estratégica:** A adoção estratégica também disparou: 95,2% das organizações consideram a IA uma prioridade estratégica para 2026, contra apenas 32,8% que investiam na tecnologia em 2024.
- **Foco em Infraestrutura:** Cerca de 45% de todo o investimento previsto para 2026 está relacionado à infraestrutura de IA, incluindo componentes como armazenamento em nuvem, processamento e pipelines de dados.

"Toda essa evolução da IA depende de algo fundamental: dados bem armazenados, organizados, protegidos e disponíveis para utilização. Não existe IA de qualidade sem uma base de dados histórica adequada por trás."

O projeto, portanto, representa um problema cada vez mais relevante: **Como construir uma infraestrutura capaz de transformar o crescimento da quantidade de dados em um ativo estratégico, sem comprometer segurança, disponibilidade e sustentabilidade financeira?**

2. Contextualização do Projeto

A **Startup Jarva's** é uma empresa em fase de hipercrescimento que oferece uma plataforma SaaS voltada para **extração inteligente de dados utilizando Inteligência Artificial**.

Como parte desse serviço, a plataforma recebe documentos enviados pelos clientes, principalmente **PDFs e imagens**, que servem como insumo para o processamento da IA. O volume previsto é de aproximadamente **50 mil novos arquivos por mês**, equivalente a cerca de **600 mil arquivos por ano**, com tendência de crescimento contínuo.

Diretriz Crítica do Negócio: Os arquivos não podem ser deletados. Os documentos antigos continuam tendo valor porque representam o histórico utilizado como base para o treinamento de futuros modelos de Inteligência Artificial.

Portanto, à medida que a empresa cresce, sua quantidade de dados também cresce continuamente. Em poucos anos, a plataforma poderá acumular milhões de documentos. Esse histórico representa não apenas uma grande quantidade de dados, mas um ativo intelectual que pode contribuir diretamente para a evolução da empresa e de seus modelos de IA.

3. Problema a ser Resolvido e Impacto no Negócio

O problema da Startup Jarva's é resultado da combinação de crescimento acelerado, necessidade de isolamento entre clientes, retenção permanente dos documentos e controle dos custos de armazenamento.

3.1 Segurança e isolamento dos dados

A plataforma possui natureza **multi-tenant**, ou seja, diferentes clientes utilizam a mesma aplicação e sua infraestrutura. Isso cria uma necessidade fundamental: **Um cliente não pode ter acesso aos documentos pertencentes a outro cliente.**

Os usuários precisam conseguir acessar seus próprios documentos de maneira rápida e segura, mas sem que uma falha de configuração, permissão ou implementação permita que arquivos de outros usuários sejam expostos. Essa necessidade de isolamento precisa ser considerada desde o início da arquitetura, e não tratada posteriormente como uma correção.

 **Contextualização de Risco:** Em 2022, um vazamento amplamente divulgado associado a uma implantação do Elasticsearch ilustrou os riscos graves de configurações inadequadas de infraestrutura e exposição indevida de

dados. Uma configuração ou implantação inadequada pode transformar uma infraestrutura que deveria proteger dados em uma porta de acesso a eles.

3.2 Retenção dos documentos e Custo de armazenamento

Ao contrário de sistemas em que dados antigos podem ser descartados, a Startup Jarva's possui a exigência de que nenhum arquivo seja excluído na operação normal. Com ~50 mil novos arquivos mensais (~600 mil/ano), o volume cresce continuamente.

Manter todos esses documentos permanentemente em uma classe de armazenamento voltada para acesso frequente geraria um custo insustentável. Por isso, a solução adota o gerenciamento do **ciclo de vida dos dados (S3 Lifecycle)**:

- **Primeiros 12 meses:** Os documentos permanecem no **Amazon S3 Intelligent-Tiering**, atendendo ao período de maior frequência de acesso e disponibilidade imediata.
- **Após 12 meses:** Uma regra de S3 Lifecycle realiza a transição automática dos objetos para o **S3 Glacier Deep Archive**, reduzindo drasticamente o custo de armazenamento dos documentos históricos sem descartá-los.

3.3 O dilema central

A arquitetura precisa responder simultaneamente a quatro pilares:

1. ⚡ **Acesso rápido:** acesso imediato e transparente durante os primeiros 12 meses.
2. 📁 **Retenção permanente:** preservação contínua do acervo sem exclusão operacional.
3. 💰 **Custo sob controle:** transição automática de classes de armazenamento para otimização orçamentária.
4. 🛡️ **Isolamento e segurança:** garantia estrita de privacidade multi-tenant.

4. Requisitos do Projeto e da Solução

- 🛡️ **Segurança:** Isolamento rigoroso entre clientes e controle de acesso restrito ao proprietário autorizado.
- 📈 **Escalabilidade:** Suporte nativo ao volume crescente (50k+ arquivos/mês) sem necessidade de dimensionamento manual.
- 🛡️ **Durabilidade e retenção:** Preservação permanente dos documentos históricos contra exclusão indevida.
- ⚡ **Disponibilidade e acesso:** Acesso rápido durante a janela de maior uso (primeiros 12 meses).
- 💰 **Economia:** Redução automatizada do custo de guarda conforme o envelhecimento do arquivo.
- 📊 **Operação e acompanhamento:** Rastreabilidade de ações, logs operacionais e controle de orçamento ativo.
- 🔄 **Reprodutibilidade:** Infraestrutura 100% declarada como código (IaC).
- 🧱 **Resiliência e tolerância a falhas:** Arquitetura serverless eliminando pontos únicos de falha.

5. Solução Proposta

5.1 Visão Geral e Arquitetura Serverless

A proposta desenvolvida utiliza uma arquitetura **serverless** baseada em serviços gerenciados da AWS, separando claramente as responsabilidades de autenticação, controle de acesso, lógica de negócio, armazenamento, metadados e observabilidade.

O fluxo de acesso utiliza a estratégia de **URLs pré-assinadas temporárias**. O cliente faz upload e download de arquivos diretamente no Amazon S3, sem que o conteúdo passe pelo API Gateway ou AWS Lambda. Isso reduz o custo de processamento, aumenta a velocidade e garante o isolamento seguro.

5.2 Serviços AWS Utilizados

Serviço AWS	Papel na Solução
 Amazon Cognito	Autenticação e gerenciamento de identidade dos usuários, emissão de tokens JWT.
 Amazon API Gateway	Camada de entrada REST, validação de autorização e integração com Lambda.
 AWS Lambda	Execução da lógica de negócio, consulta de permissões e geração de URLs pré-assinadas.
 Amazon DynamoDB	Armazenamento de metadados e propriedade dos documentos para validação de acesso.
 Amazon S3 Intelligent-Tiering	Classe inicial de armazenamento que ajusta automaticamente o nível de acesso nos primeiros 12 meses.
 S3 Lifecycle	Automação do ciclo de vida e transição programada de objetos após 12 meses.
 S3 Glacier Deep Archive	Guarda de longo prazo para preservação de ativos históricos a custo mínimo.
 S3 Object Lock	Proteção de imutabilidade dos objetos contra alterações ou exclusões indevidas.
 AWS IAM	Gestão de políticas de acesso restritas pelo Princípio do Menor Privilégio.
 Amazon CloudWatch	Monitoramento operacional, métricas, dashboards e alarmes de execução.
 AWS CloudTrail	Auditoria completa e registro rastreável de todas as chamadas de API na conta.
 AWS Budgets & Cost Explorer	Definição de alertas financeiros e análise contínua da evolução de custos de nuvem.
 AWS CloudFormation	Provisionamento padronizado da infraestrutura por código (IaC).

5.3 Jornada do Cliente

A jornada do cliente descreve a experiência do usuário integrada aos mecanismos de segurança e ciclo de vida do dado na nuvem:



Figura 1: Jornada do Cliente — Do envio do documento à preservação segura do ativo histórico.

5.4 Arquitetura Técnica AWS

A visão técnica detalha os componentes da arquitetura serverless desenvolvida para a Fase 01 do projeto:




Figura 2: Arquitetura da Solução na AWS (Fase 01) — Serverless, Segura, Escalável e Otimizada para Custos.

5.5 Resiliência, Frameworks e Governança

- **Resiliência e Tolerância a Falhas:** O uso de serviços serverless (S3, Lambda, DynamoDB, API Gateway) delega à AWS a distribuição automática de dados e execução em múltiplas Zonas de Disponibilidade (AZs), garantindo 99,999999999% de durabilidade dos dados.
- **AWS CAF e Well-Architected Framework:** Alinhado aos pilares de Segurança, Excelência Operacional, Confiabilidade, Eficiência de Performance, Otimização de Custos e Sustentabilidade, com infraestrutura codificada via CloudFormation.

6. Como o Projeto foi Desenvolvido

O projeto foi desenvolvido seguindo uma metodologia estruturada em etapas:

1. **Análise do Problema e Mapeamento de Requisitos:** Levantamento detalhado das necessidades operacionais, do volume de dados (50k/mês) e do dilema entre acesso x retenção x custo.
2. **Desenho da Solução Arquitetural:** Escolha da abordagem Serverless e definição da estratégia de transferências diretas via URLs pré-assinadas para maximizar segurança e reduzir gargalos.
3. **Modelagem de Dados e Segurança:** Definição da tabela no DynamoDB para vincular metadados ao ID do usuário e criação de regras estritas do IAM.
4. **Infraestrutura como Código (IaC):** Criação dos templates no AWS CloudFormation para garantir a reprodutibilidade e automação total do ambiente.

7. Infraestrutura como Código (IaC)

A utilização do **AWS CloudFormation** assegura que toda a infraestrutura da Startup Jarva's seja tratada como código. Isso permite criar ambientes idênticos de desenvolvimento, homologação e produção com facilidade, reduzindo erros manuais, garantindo conformidade com as boas práticas de governança e permitindo o versionamento completo da arquitetura.

8. Evolução e Visão de Futuro — Fase 02

Para a evolução da plataforma na Fase 02, estão planejadas as seguintes melhorias:

- **AWS KMS:** Gerenciamento customizado de chaves de criptografia para atender requisitos rígidos de conformidade.
- **Amazon EventBridge & AWS Step Functions:** Processamento assíncrono e orquestrado de pipelines de extração de dados via IA.
- **Amazon CloudFront & S3 Transfer Acceleration:** Otimização de latência no envio e acesso a documentos por clientes em regiões remotas.
- **Pipelines de Treinamento de IA:** Consumo automatizado da base histórica armazenada no Glacier para treinamento e aperfeiçoamento contínuo dos modelos.

9. Agradecimentos

Agradecemos à **Escola da Nuvem**, aos instrutores e à comunidade de alunos pelo suporte, conhecimento compartilhado e pela oportunidade prática proporcionada durante o desenvolvimento deste projeto desafiador.

10. Referências

- AWS Documentation. *Amazon S3 Intelligent-Tiering & Lifecycle Rules*. Disponível em: <<https://aws.amazon.com/s3/>>.
- AWS Well-Architected Framework. *Architecting for the Cloud: Best Practices*. AWS Whitepapers.
- Gartner. *Forecast: Enterprise Information Technology Services, Worldwide (2024-2027)*.
- IBM Institute for Business Value. *Estudo sobre Adoção de Inteligência Artificial nas Empresas Brasileiras*.
- Repositório oficial do projeto: <https://github.com/lbarretto/jarvas-aws-architecture>.